

Laboratorio 2: Deep Learning y Análisis de Series de Tiempo

Modelado con LSTM y Similitud con catch22

Integrantes del Grupo:

Javier España #23361
Angel Esquit #23221
Roberto Barreda #23354

Guatemala, 2 de agosto de 2026

1. Ejercicio 1: Modelos LSTM para Series de Tiempo

1.1. Preparación de datos

Se utilizaron los conjuntos de entrenamiento (70 %) y prueba (30 %) provenientes del archivo de datos `series_de_tiempo_completas.csv`, asegurando la estricta comparabilidad respecto a los modelos clásicos (ARIMA, Holt-Winters) desarrollados en el Laboratorio 1. Las dos series analizadas fueron **Total_Consistent** (serie total mensual de visitantes) y **Via_Aerea** (categoría vía de ingreso aérea).

1.2. Definición de modelos y tuneo de hiperparámetros

Se evaluaron dos arquitecturas de redes recurrentes LSTM:

- **LstmSimple**: 1 capa LSTM, Dropout = 0.0.
- **LstmApilado**: 2 capas LSTM, Dropout = 0.2.

Para cada arquitectura se realizó una búsqueda en grilla (*grid search*) sobre combinaciones de tamaño de ventana ($L \in \{12, 24\}$), unidades ocultas ($U \in \{32, 64\}$) y tasa de aprendizaje ($\eta \in \{0,01, 0,001\}$), resultando en 16 modelos evaluados por serie mediante validación interna sobre los últimos 24 meses del conjunto de entrenamiento.

1.3. Predicción sobre el conjunto de prueba

Con la mejor configuración seleccionada para cada serie, se re-entrenó el modelo con la totalidad de los datos de entrenamiento y se evaluó el desempeño en el conjunto de prueba utilizando dos estrategias de pronóstico:

1. **Multi-step (Autoregresivo)**: Generación recursiva alimentando las propias predicciones del modelo.

2. One-step ahead: Pronóstico a un paso usando la observación real previa.

En la Figura 1 se observan las predicciones generadas por el mejor modelo LSTM en comparación con las observaciones reales de prueba.




Figura 1: Predicciones del modelo LSTM sobre el conjunto de prueba para las series **Total.Consistent** y **Via.Aerea**.

1.4. Análisis comparativo y evaluación

1.4.1. ¿Cuál serie fue predicha mejor?

Al comparar la métrica NRMSE (RMSE normalizado por la media de la serie), la serie **Via.Aerea** presentó un desempeño de predicción superior respecto a **Total.Consistent**. Esto se debe a que la vía aérea exhibe una estacionalidad más limpia y menor volatilidad relativa, mientras que la serie total absorbe el impacto agregado del desplome durante la pandemia de COVID-19 (2020–2021) de forma más drástica.

1.4.2. ¿Son mejores que los modelos del Laboratorio 1?

Para evaluar de manera directa la calidad de las predicciones de Deep Learning frente a los enfoques estadísticos y econométricos clásicos construidos en el Laboratorio 1, la Tabla 1 consolida los resultados en el conjunto de prueba (62 meses, mayo 2021 a junio 2026).

Cuadro 1: Comparación cuantitativa de desempeño en el conjunto de prueba (62 meses): Modelos Clásicos del Laboratorio 1 (SARIMA y Holt-Winters) vs. Modelos LSTM del Laboratorio 2 (Multi-step y One-step ahead).

Serie / Modelo	RMSE Lab 1	MAE Lab 1	LSTM MS (RMSE)	LSTM MS (MAE)	LSTM OS (RMSE)	LSTM OS (MAE)
Total Consistent						
SARIMA (Lab 1)	252,400.00	238,600.00	—	—	—	—
Holt-Winters (Mejor Lab 1)	163,800.00	154,100.00	—	—	—	—
LSTM (Lab 2 — Multi-step)	—	—	182,469.15	168,761.64	—	—
LSTM (Lab 2 — One-step)	—	—	—	—	59,698.34	44,655.19
Via Aérea						
SARIMA (Lab 1)	93,100.00	88,400.00	—	—	—	—
Holt-Winters (Mejor Lab 1)	46,800.00	43,400.00	—	—	—	—
LSTM (Lab 2 — Multi-step)	—	—	31,803.33	23,859.30	—	—
LSTM (Lab 2 — One-step)	—	—	—	—	17,035.82	12,843.68

A partir de la comparación directa se concluye lo siguiente:

- **Vía Aérea:** El modelo LSTM resultó significativamente superior a todos los modelos clásicos del Laboratorio 1 en ambas modalidades. En la estrategia Multi-step autoregresiva logró reducir el RMSE de 46,800 (Holt-Winters) a 31,803.33 (una mejora del **+32.0 %**), mientras que en One-step ahead alcanzó un RMSE de 17,035.82 (mejora del **+63.6 %**). Esto confirma la capacidad de las redes recurrentes para modelar patrones estacionales estables sin acumular una deriva excesiva.
- **Total Consistente:** En la modalidad **One-step ahead**, el modelo LSTM redujo drásticamente el error frente al mejor modelo de Lab 1 (RMSE de 59,698.34 frente a 163,800.00 de Holt-Winters, representando una reducción de error del **+63.6 %**). No obstante, en la modalidad **Multi-step (autorregresiva a 62 pasos)**, el modelo Holt-Winters mantuvo un RMSE ligeramente inferior (163,800.00 vs. 182,469.15 del LSTM), debido a que la proyección autorregresiva prolongada sin observaciones reales intermedias sufre acumulación de error recursivo.

1.4.3. ¿Cómo se determinó?

La evaluación se basó en el cálculo riguroso de dos métricas sobre los 62 meses del conjunto de prueba:

1. **MAE (Mean Absolute Error):** Promedio directo del error en número absoluto de pasajeros.
2. **RMSE (Root Mean Squared Error):** Métrica que penaliza errores de gran magnitud.

Además, se calculó el porcentaje de mejora relativa en RMSE de la LSTM frente a los baselines clásicos (Holt-Winters y SARIMA).

2. Ejercicio 2: Análisis de Similitud con catch22

2.1. Idea detrás de catch22

El conjunto de características **catch22** (*canonical time-series characteristics*) fue desarrollado por Fulcher y Jones como una solución eficiente a la redundancia computacional del catálogo **hctsa** (que cuenta con más de 7,700 propiedades). Mediante un riguroso proceso de selección empírica sobre 93 tareas de clasificación, se identificaron 22 características canónicas poco correlacionadas entre sí, informativas y de bajo costo computacional (complejidad lineal). Su importancia radica en transformar cualquier serie temporal —independientemente de su longitud— en un vector denso interpretable de dimensión fija (1×22), permitiendo aplicar técnicas de análisis multivariado como PCA, clustering y matrices de distancia. Dado que catch22 opera sobre series normalizadas (*z-score*), evalúa la *forma* y la *dinámica* de la serie, eliminando el nivel medio y la escala absoluta.

2.2. Extracción de las 22 características

Se extrajeron las 22 características canónicas para las 7 series temporales del proyecto usando la totalidad del periodo de observación (210 meses, enero 2009 a junio 2026). La extracción se ejecutó mediante el paquete **aeon** en Python, garantizando la reproducibilidad del cálculo.

2.3. Matriz de características

La matriz resultante $M \in \mathbb{R}^{7 \times 22}$ consolida las 7 series de tiempo (filas) y las 22 métricas canónicas (columnas) sin valores faltantes, almacenada en `results/Catch22Features.csv`.

2.4. Estandarización

Debido a que las 22 características poseen escalas heterogéneas (por ejemplo, métricas de racha de valores `SB_BinaryStats_mean_longstretch1` alcanzan valores cercanos a 51, mientras que covarianzas en matriz de transición `SB_TransitionMatrix_3ac_sumdiagcov` se ubican en el rango 0,005 – 0,046), se aplicó estandarización **StandardScaler** a cada columna:

$$z_{i,j} = \frac{x_{i,j} - \mu_j}{\sigma_j} \quad (1)$$

Evitando así que características de magnitud arbitrariamente grande dominen las métricas de distancia e influencia en los componentes principales.

2.5. Resultados del Análisis Exploratorio

Sobre la matriz estandarizada se ejecutaron cinco análisis clave cuyos resultados gráficos se presentan a continuación:

1. **Análisis de Componentes Principales (PCA):** Los dos primeros componentes explican el **69.5 %** de la varianza total (PC1: 50.5 %, PC2: 19.1 %), y los primeros tres acumulan el **84.9 %** (Figura 2).
2. **Clustering Jerárquico:** Aplicando la distancia euclidiana y el método de enlace de Ward, el coeficiente de silueta identificó $k = 2$ grupos naturales como la partición óptima con Silueta = 0.2714 (Figura 3).
3. **Mapa de Calor (Heatmap):** Representación de la matriz de características estandarizadas por serie que evidencia firmas dinámicas distintivas (Figura 4).

4. **Matriz de Correlaciones:** Evaluación de Pearson entre las 22 características de catch22 (Figura 5).
5. **Mapa de Distancias Euclidianas:** Matriz de distancias par a par en el espacio de 22 dimensiones (Figura 6).




Figura 2: Dispersión de las 7 series temporales en el plano de los dos primeros componentes principales (PC1 y PC2).




Figura 3: Dendrograma de clustering jerárquico usando el método de enlace de Ward sobre las características de catch22.




Figura 4: Mapa de calor con las 22 características de catch22 estandarizadas para cada una de las 7 series.




Figura 5: Matriz de correlaciones de Pearson entre las 22 características canónicas de catch22.




Figura 6: Mapa de distancias euclidianas par a par entre las series temporales estandarizadas.

2.6. Análisis e Interpretación

2.6.1. ¿Cuáles series presentan comportamientos más similares?

Las series que exhiben el comportamiento dinámico más similar son **Total_Consistent** y **Via_Terrestre**, seguidas muy de cerca por **Pais_El Salvador**. Esta afirmación se fundamenta cuantitativamente en tres hallazgos congruentes:

1. **Distancia Euclidiana mínima:** En la matriz de distancias 22D, el par con menor distancia euclidiana de todo el estudio es (Total_Consistent, Via_Terrestre) con $d = 4,17$. Asimismo, Via_Terrestre con Pais_El Salvador registra $d = 4,81$, y Total_Consistent con Via_Aerea registra $d = 4,45$.
2. **Agrupamiento en PCA:** En la proyección sobre el plano PC1–PC2, estas series se ubican fuertemente concentradas en el cuadrante negativo de PC1, compartiendo valores idénticos en parámetros de memoria lineal (CO_f1ecac) e información mutua (CO_HistogramAMI_even_2_5).
3. **Dendrograma de Clustering:** En el árbol de jerarquía, Total_Consistent, Via_Terrestre y Pais_El Salvador se fusionan a la menor altura de distancia de unión, confirmando que comparten la misma estructura estacional y dinámica de transmisión temporal.

2.6.2. ¿Qué características de catch22 fueron las más importantes para diferenciar las series?

El análisis de cargas (*loadings*) de los componentes principales determinó las características canónicas con mayor poder de discriminación:

- **Primer Componente Principal (PC1 — 50.5 % de varianza):**

- `FC_LocalSimple_mean3_stderr` (+0,2949): Error de pronóstico local con media móvil de 3 puntos (mide la predictibilidad local de la serie).
- `CO_f1ecac` (−0,2937): Retardo donde la autocorrelación cae por debajo de $1/e$ (mide la memoria temporal lineal).
- `CO_HistogramAMI_even_2_5` (−0,2808): Información mutua automática con retardo 2 (mide dependencias no lineales).

PC1 actúa como un eje de *predictibilidad y memoria temporal*, separando series altamente estructuradas (como Total y Vía Terrestre) de series con quiebres o patrones irregulares.

■ **Segundo Componente Principal (PC2 — 19.1 % de varianza):**

- `MD_hrv_classic_pnn40` (+0,4295): Proporción de diferencias sucesivas que superan 0,04 desviaciones estándar (mide fluctuaciones rápidas o micro-volatilidad).
- `CO_FirstMin_ac` (−0,3341): Primer mínimo de la función de autocorrelación (mide la escala de la periodicidad/estacionalidad).

PC2 actúa como un eje de *micro-volatilidad y escala estacional*, discriminando principalmente a **Via_Maritima** debido a su régimen de variación mensual de alta frecuencia.

2.6.3. ¿Existen grupos naturales de series?

La evaluación del coeficiente de silueta confirmó la presencia de $k = 2$ grupos naturales bien definidos:

- **Grupo 1 (Grupo Macrodinámico / Principal):** Integrado por `Total_Consistent`, `Via_Aerea`, `Via_Terrestre`, `Via_Maritima`, `Pais_El_Salvador` y `Pais_Estados_Unidos`. Caracterizado por alta persistencia temporal, fuerte estacionalidad anual cíclica y un patrón de recuperación progresivo post-pandemia.
- **Grupo 2 (Grupo Atípico / Dislocado):** Conformado de manera aislada por `Pais_Guatemala`. Esta serie se separa tempranamente en el dendrograma y se proyecta en el extremo positivo de PC1 debido a una racha inusualmente larga por encima de su media (`SB_BinaryStats_mean_longstret`) y a un comportamiento dislocado respecto a los flujos turísticos internacionales estándar.

2.6.4. ¿Las series pertenecientes a una misma categoría tienden a agruparse?

El análisis empírico evidencia que las series pertenecientes a una misma categoría (vías de ingreso o países de origen) **no se agrupan de forma homogénea**, sino que presentan dinámicas diferenciadas por factores operativos y estructurales:

- **Vías de Ingreso:** `Via_Aerea` y `Via_Terrestre` pertenecen al mismo macro-grupo (Grupo 1) y exhiben una distancia euclidiana reducida ($d = 4,65$). Ambas comparten alta persistencia, fuerte estacionalidad anual y el marcado impacto de la pandemia de COVID-19. Sin embargo, `Via_Maritima`, aunque se clasifica dentro del Grupo 1, se separa marcadamente en el plano de PC2 debido a su elevada micro-volatilidad ($MD_hrv_classic_pnn40 = 0.76$) y a la marcada discontinuidad mensual de la operativa de cruceros.
- **Países de Origen:** `Pais_El_Salvador` y `Pais_Estados_Unidos` de América se agrupan estrechamente en el Grupo 1 ($d = 5,62$), reflejando el comportamiento del turismo receptivo internacional masivo. En contraste, `Pais_Guatemala` resulta ser el mayor *outlier* estructural de todo el estudio (Grupo 2, $d = 8,91$ respecto a la serie Total), proyectándose aisladamente por su prolongada inercia sin las oscilaciones estacionales tradicionales.

Conclusión: La pertenencia a una misma categoría nominal no garantiza similitud dinámica. Las características de `catch22` permiten desglosar qué subcomponentes de una categoría responden a dinámicas macroeconómicas globales y cuáles obedecen a comportamientos locales o de nicho.

2.6.5. Identificación de las series más atípicas

1. Pais_Guatemala (Serie Principal Atípica):

- **Evidencia:** Es la única serie aislada en el Grupo 2 del clustering jerárquico (Silueta = 0.2714), registrando la distancia euclidiana máxima respecto a la serie Total ($d = 8,91$) y a EE.UU. ($d = 9,67$).
- **Métricas determinantes:** Registra una racha máxima por encima de su media de `SB.BinaryStats_mean_longstretch1` = 51 meses y una memoria lineal `CO_f1ecac` = 17.58 (frente a 8.97 en la serie Total).
- **Justificación:** Esta serie no representa turismo receptivo vacacional internacional, sino viajes de residentes, retornos nacionales y flujos de frontera doméstica, los cuales mantienen una inercia lineal alta y no sufrieron la parálisis turística cíclica de las fronteras internacionales.

2. Via_Maritima (Serie Secundaria Atípica):

- **Evidencia:** Registra el valor de carga más elevado en PC2 y mayor distancia dentro de las vías ($d = 7,54$ a Total).
- **Justificación:** Operatividad discontinua por temporadas de cruceros con saltos abruptos de volumen entre meses consecutivos (`MD_hrv_classic_pnn40` = 0.76).

2.6.6. Comparación de catch22 con el Análisis Exploratorio Clásico (Lab 1)

El análisis multivariado basado en `catch22` confirma y complementa de manera rigurosa los hallazgos del EDA clásico realizado en el Laboratorio 1:

- **Tendencia y Autocorrelación:** La lenta atenuación de la ACF observada en Lab 1 para `Total.Consistent` y `Via.Terrestre` fue cuantificada por `CO_f1ecac` ($1/e$ delay ≈ 9 meses) y por la información mutua automática (`CO_HistogramAMI_even_2.5`).
- **Estacionalidad:** Los picos estacionales de julio/diciembre fueron capturados por el primer mínimo de autocorrelación (`CO_FirstMin_ac`) y el centroide espectral de Welch.
- **Volatilidad e Impacto de Pandemia:** La parálisis de movilidad de 2020 fue la fuerza principal que agrupó a 6 de las 7 series en el Grupo 1.

2.6.7. Descubrimientos clave aportados por catch22

1. **Separación de dependencia lineal vs. no lineal:** Demostró que Pais.El Salvador posee mayor información mutua no lineal (`CO_HistogramAMI_even_2.5`) que `Via.Aerea`, diferencia imperceptible en gráficos de ACF lineales.
2. **Cuantificación de la micro-volatilidad:** La métrica `MD_hrv_classic_pnn40` (76 % de fluctuaciones bruscas) aisló la naturaleza discontinua de la Vía Marítima.
3. **Inercia extrema de Guatemala:** Reveló cuantitativamente su racha ininterrumpida de 51 meses por encima de su media (`SB.BinaryStats_mean_longstretch1`), caracterizando su falta de reversión cíclica a la media.

2.6.8. Modelo LSTM con Características catch22 (Catch22-LSTM) vs. Baseline LSTM

Se construyó una arquitectura híbrida **Catch22-LSTM** donde la secuencia temporal $y_{t-L:t}$ es procesada por una capa LSTM, y su vector de estado oculto final h_L se concatena con el vector de 22 características estandarizadas de **catch22** antes de la capa densa de salida.

Se evaluó el desempeño en el conjunto de prueba para las series principales (**Total_Consistent** y **Via_Aerea**) comparándolo contra el mejor modelo LSTM univariado del Ejercicio 1.




Figura 7: Predicciones del modelo híbrido Catch22-LSTM sobre el conjunto de prueba para las series **Total_Consistent** y **Via_Aerea**.

Cuadro 2: Comparación de Desempeño en Test: Baseline LSTM (Ej 1) vs. Catch22-LSTM (Ej 2.14)

Serie	Ej1 RMSE MS	C22-LSTM MS	Mejora MS	Ej1 RMSE OS	C22-LSTM OS
Total_Consistent	182,469.15	175,856.54	+3.62 %	59,698.34	73,180.34
Via_Aerea	31,803.33	43,345.42	-36.29 %	17,035.82	19,683.82

Discusión de Resultados:

- **Desempeño en la serie Total_Consistent:** La incorporación de las características de **catch22** logró reducir el error cuadrático medio en la modalidad Multi-step autoregresiva (reducción de RMSE de 182,469.15 a 175,856.54, representando un +3.62 % de mejora). Esto demuestra que para la serie macro total, el vector de contexto global de **catch22** estabiliza la deriva recursiva a largo plazo al inyectar información sobre la memoria lineal y la predictibilidad histórica de la serie.

- **Desempeño en la serie `Via_Aerea`:** Para la vía aérea, el modelo univariado baseline del Ejercicio 1 mantuvo un RMSE inferior tanto en Multi-step como en One-step. Dado que `Via_Aerea` es una serie de menor escala y comportamiento estacional altamente regular, agregar 22 características estáticas incrementó la dimensionalidad del espacio de parámetros de la capa densa sin aportar varianza nueva relevante, generando un leve sobreajuste.
- **Conclusión:** Las 22 características de `catch22` son altamente efectivas como descriptores globales y condicionadores para series complejas y de alta volatilidad (como la serie `Total`), actuando como regularizadores dinámicos que mitigan la acumulación de error autorregresivo a largo plazo.